

Real-Time PM 2.5 Monitoring Dashboard

1. ความเป็นมา

ในยุคปัจจุบันที่ขับเคลื่อนด้วยข้อมูล ความสามารถในการรวบรวม ประมวลผล และแสดงผลข้อมูลแบบเรียลไทม์ ถือเป็นปัจจัยสำคัญที่ช่วยสนับสนุนการตัดสินใจในหลากหลายอุตสาหกรรม ตั้งแต่การเกษตรไปจนถึงการวางผังเมือง โดยเฉพาะในบริบทของคุณภาพอากาศการมีระบบที่สามารถตรวจวัดค่าฝุ่นละอองในอากาศแบบเรียลไทม์ได้อย่างแม่นยำ จะช่วยให้ภาครัฐ ภาคเอกชน และประชาชนสามารถรับมือกับปัญหาฝุ่นละอองขนาดเล็ก (PM2.5) ได้อย่างมีประสิทธิภาพและทันทั่วถึง

การพัฒนา Data Pipeline ซึ่งเป็นกระบวนการที่จัดการการไหลของข้อมูลตั้งแต่การดึงข้อมูลจากแหล่งต้นทาง ไปจนถึงการจัดเก็บและแสดงผลแบบอัตโนมัติเป็นหัวใจสำคัญของการบริหารจัดการข้อมูลแบบเรียลไทม์ อย่างไรก็ตาม การออกแบบระบบ pipeline ดังกล่าวมักมีความซับซ้อน เนื่องจากต้องอาศัยความรู้ด้านการจัดการ workflow การใช้ containerization และเครื่องมือสำหรับการแสดงผลข้อมูล

โครงการนี้มีเป้าหมายเพื่อขยายแนวคิดเชิงทฤษฎีไปสู่การประยุกต์ใช้งานจริง โดยมุ่งเน้นการพัฒนา pipeline ที่สามารถดึงข้อมูลค่าฝุ่น PM2.5 จาก API (เช่น OpenWeatherMap) ในทุก ๆ 15 นาที จากนั้นทำการจัดเก็บข้อมูลในฐานข้อมูลที่มีน้ำหนักเบา (lightweight) เช่น PostgreSQL และแสดงผลผ่านแดชบอร์ดแบบ interactive เพื่อให้ผู้ใช้งานสามารถติดตามสถานการณ์คุณภาพอากาศได้แบบเรียลไทม์

นอกจากนี้ โครงการยังมุ่งสำรวจความเป็นไปได้ในการประยุกต์ใช้ Machine Learning (ML) เพื่อคาดการณ์แนวโน้มค่าฝุ่นในอนาคต ซึ่งจะช่วยยกระดับระบบจากการรายงานสถานการณ์สู่การวิเคราะห์เชิงคาดการณ์ (Predictive Analytics) ที่มีคุณค่าในเชิงการวางแผนและการตัดสินใจ

โครงการนี้มีระยะเวลาดำเนินการทั้งหมด 3 สัปดาห์ ครอบคลุมการออกแบบ พัฒนา และจัดแสดงผลระบบแดชบอร์ดสำหรับ PM2.5 แบบเรียลไทม์ โดยใช้เครื่องมือสำคัญ ได้แก่ Prefect, Docker, PostgreSQL, และเครื่องมือสำหรับสร้างแดชบอร์ด เช่น Streamlit หรือ Looker Studio โดยมีจุดมุ่งหมายให้สามารถนำไปต่อยอดใช้งานได้จริง ทั้งในบริบทของการวิจัย การเฝ้าระวังคุณภาพอากาศในชุมชน หรือการสนับสนุนการวางแผนในระดับท้องถิ่น

2. วัตถุประสงค์ของโครงการ

วัตถุประสงค์หลักของโครงการ Real-Time PM2.5 Monitoring Dashboard คือการพัฒนา ระบบ pipeline ที่สามารถเก็บ ประมวลผล จัดเก็บ และแสดงผลข้อมูลค่าฝุ่นละอองขนาดเล็ก PM2.5 ได้แบบเรียลไทม์ทุก 15 นาที โดยมีเป้าหมายเพื่อแสดงกระบวนการทำงานของระบบด้านวิศวกรรมข้อมูล (Data Engineering) ที่ทันสมัย โดยมีวัตถุประสงค์เฉพาะดังนี้:

2.1 การเก็บข้อมูล : พัฒนา pipeline โดยใช้ Prefect 2 ในการดึงข้อมูลค่าฝุ่น PM2.5 และข้อมูลสภาพอากาศอื่นๆ (เช่น อุณหภูมิ ความชื้น ความเร็วลม) จาก OpenWeatherMap API ทุก ๆ 15 นาที สำหรับพื้นที่กรุงเทพมหานครหรือตำบล

- 2.2 การประมวลผลและจัดเก็บข้อมูล : ดำเนินการแปลงข้อมูลดิบจาก API เช่น การจัดการค่า null การแปลงหน่วย และการจัดรูปแบบข้อมูลให้อยู่ในโครงสร้างที่เหมาะสม พร้อมจัดเก็บในฐานข้อมูลที่รองรับการเข้าถึง เช่น Parquet ใน data lake ที่มี schema ที่กำหนดไว้อย่างชัดเจน
- 2.3 การแสดงผลข้อมูล : สร้างแดชบอร์ดแบบอินเตอร์แอคทีฟด้วย Streamlit (หรือ Looker Studio) สำหรับแสดงค่าฝุ่น PM2.5 แบบเรียลไทม์ และแนวโน้มย้อนหลัง เพื่อให้ประชาชนทั่วไปที่ไม่มีพื้นฐานด้านเทคนิคสามารถเข้าใจข้อมูลได้
- 2.4 การจัดการและการนำไปใช้งานจริง : ทำการ deploy ระบบ pipeline ในสภาพแวดล้อมแบบ container โดยใช้ Docker และ Prefect 3 เพื่อให้สามารถทำงานได้อย่างเสถียร รองรับการปรับขยายในอนาคต
- 2.5 การวิเคราะห์เชิงคาดการณ์ : มีการใช้ Machine Learning เบื้องต้น เช่น regression เพื่อพยากรณ์แนวโน้มค่าฝุ่น PM2.5 และหาปัจจัยที่ส่งผลให้ค่าฝุ่น PM2.5 มีปริมาณมาก โดยอิงจากข้อมูลที่เก็บมา เพื่อแสดงศักยภาพของระบบในการวิเคราะห์เชิงลึก

3. ประโยชน์ที่ได้รับ

โครงการ Real-Time Weather Data Pipeline มอบประโยชน์หลากหลายแก่ผู้มีส่วนได้ส่วนเสีย ไม่ว่าจะเป็นสถาบันการศึกษานักเรียน นักศึกษา และองค์กรที่สนใจด้านวิศวกรรมข้อมูล โดยประโยชน์เหล่านี้สอดคล้องกับ papapipeline และสามารถนำไปใช้จริงได้ในสถานการณ์ต่าง ๆ

3.1 ประโยชน์ด้านการศึกษา: การเรียนรู้แบบลงมือปฏิบัติ (Hands-On Learning): เสนอกรณีศึกษาเชิงปฏิบัติในการพัฒนาระบบ data pipeline ครบทุกขั้นตอน ตั้งแต่การดึงข้อมูล ประมวลผล จัดเก็บ ควบคุมการทำงาน จนถึงการแสดงผล เหมาะอย่างยิ่งสำหรับหลักสูตรด้าน data science และ data engineering *
เครื่องมือทันสมัย (Modern Tools): เปิดโอกาสให้ผู้เรียนได้ฝึกใช้งานเครื่องมือมาตรฐานระดับอุตสาหกรรม เช่น Prefect 3, Docker และ Streamlit เตรียมความพร้อมสำหรับการทำงานสายวิศวกรรมข้อมูลในอนาคต
* การประยุกต์ใช้จริง (Real-World Application): แสดงให้เห็นว่าทฤษฎี เช่น การจัดการเวิร์กโฟลว์ (workflow orchestration) สามารถนำมาใช้แก้ปัญหาในโลกจริงได้ ช่วยเสริมสร้างความสนใจและมีส่วนร่วมของนักเรียน
* การมีส่วนร่วมในโอเพ่นซอร์ส (Open-Source Contribution): โค้ดและเอกสารของโครงการที่เผยแพร่ผ่าน GitHub สามารถแบ่งปันให้กับชุมชน นำไปต่อยอดหรือใช้ในการเรียนการสอน รวมถึงเป็นส่วนหนึ่งของทรัพยากร papapipeline

3.2 ประโยชน์เชิงปฏิบัติ: การติดตามแบบเรียลไทม์ (Real-Time Monitoring): ช่วยให้ผู้ใช้งานในท้องถิ่น เช่น เกษตรกร หรือผู้จัดงาน สามารถติดตามสภาพอากาศแบบใกล้เคียงเรียลไทม์ เพื่อสนับสนุนการตัดสินใจ
* ความสามารถในการขยายระบบ (Scalability): ด้วยการออกแบบแบบโมดูลาร์ (modular design) pipeline นี้สามารถขยายไปยังหลายเมือง แหล่งข้อมูลเพิ่มเติม หรือปรับใช้บนระบบคลาวด์ได้ เหมาะสำหรับแอปพลิเคชันที่ใหญ่ขึ้น * การแสดงผลที่เข้าถึงง่าย (User-Friendly Visualization): แดชบอร์ดที่สร้างด้วย Streamlit มีอินเตอร์เฟซที่ใช้งานง่าย แม้ผู้ที่ไม่มีความรู้ทางเทคนิคก็สามารถเข้าถึงและเข้าใจข้อมูลได้
* ศักยภาพในการพยากรณ์ (Predictive Potential): โมเดล ML เสริมที่สามารถพัฒนาเพิ่มเติมได้ ช่วยปูทางสู่การวิเคราะห์เชิงพยากรณ์ เช่น การทำนายอุณหภูมิหรือรูปแบบสภาพอากาศ ซึ่งเป็นประโยชน์ต่อภาคเกษตร

3.3 ประโยชน์ต่อองค์กร : ต้นแบบต้นทุนต่ำ (Low-Cost Prototype): สร้างขึ้นโดยใช้เครื่องมือที่ให้อิสระฟรี เช่น OpenWeatherMap API, ไฟล์ Parquet และ Streamlit ลดต้นทุนในขณะที่ยังคงให้ระบบที่ใช้งานได้จริง

* รากฐานสำหรับการต่อยอด (Foundation for Growth): ทำหน้าที่เป็นต้นแบบ (proof-of-concept)

สำหรับองค์กรที่ต้องการนำระบบ real-time data pipeline ไปใช้จริง โดยสามารถพัฒนาเพิ่มเติมให้เชื่อมต่อกับระบบ

* การมีส่วนร่วมของชุมชน (Community Engagement): สอดคล้องกับโครงการส่งเสริมความรู้ด้านข้อมูล (data literacy) และการพัฒนาแบบโอเพ่นซอร์ส โดยเฉพาะในบริบทด้านการศึกษาและท้องถิ่น เช่นในประเทศไทยตามแนวทางของ papapipeline

4. ตัวชี้วัดความสำเร็จของโครงการ (Key Performance Indicators)

เพื่อประเมินความสำเร็จของโครงการตลอดระยะเวลา 3 สัปดาห์ ได้กำหนดตัวชี้วัดหลัก (KPI) ใน 3 ด้าน ได้แก่ ด้านเทคนิค ด้านการศึกษา และด้านการใช้งานจริง ดังนี้

4.1 ตัวชี้วัดด้านเทคนิค (Technical KPIs)

ความเสถียรของระบบดึงข้อมูล (Pipeline Reliability) * เป้าหมาย: ดึงข้อมูลค่าฝุ่นจาก API สำเร็จอย่างน้อย 95% ของรอบทั้งหมดใน 24 ชั่วโมง (จาก 96 รอบต่อวัน) * วิธีวัดผล: ตรวจสอบสถานะการทำงานของ flow ผ่าน Prefect UI ว่ามีสถานะสำเร็จ (Success) กี่รอบ

ปริมาณข้อมูลที่จัดเก็บ (Data Volume) * เป้าหมาย: เก็บข้อมูลค่าฝุ่นและสภาพอากาศอย่างน้อย 1,000 แถวในรูปแบบไฟล์ Parquet * วิธีวัดผล: ใช้คำสั่ง query เพื่อนับจำนวน record ที่จัดเก็บไว้

การทำงานของแดชบอร์ด (Dashboard Functionality) * เป้าหมาย: แดชบอร์ดอัปเดตข้อมูลใหม่ทุก 15 นาที และสามารถโหลดหน้าได้ภายใน 3 วินาที ในอย่างน้อย 90% ของการใช้งาน * วิธีวัดผล: ทดสอบความเร็วในการโหลดหน้า และดูการอัปเดตข้อมูลแบบ manual

ความเสถียรของระบบ Deployment (Deployment Stability) * เป้าหมาย: ระบบที่รันผ่าน Docker (เช่น Jupyter, Prefect, Streamlit) ต้องเปิดทำงานต่อเนื่องได้ไม่น้อยกว่า 24 ชั่วโมง * วิธีวัดผล: ตรวจสอบ log และสถานะ container ว่ารันได้ต่อเนื่องโดยไม่ล้ม

4.2 ตัวชี้วัดด้านการศึกษา (Educational KPIs)

คุณภาพของเอกสารและคู่มือ (Documentation Quality) * เป้าหมาย: สร้าง README ใน GitHub และรายงานโครงการที่อธิบายวิธีติดตั้ง การใช้งาน และผลลัพธ์ได้ชัดเจน โดยผู้รีวิวให้คะแนนเฉลี่ย 4/5 * วิธีวัดผล: ขอ feedback จากเพื่อนหรือนักศึกษาในสาขาเดียวกัน 3-5 คน

ผลลัพธ์การเรียนรู้ของผู้ใช้ (Learning Outcomes) * เป้าหมาย: นักศึกษารุ่นน้องที่ทดลองใช้งานอย่างน้อย 80% สามารถติดตั้งและรันระบบได้เองภายในเวลา 2 ชั่วโมง * วิธีวัดผล: ทดสอบกับนักศึกษากลุ่มเล็ก 5-10 คน แล้วเก็บข้อมูลเวลาและความสำเร็จ

การมีส่วนร่วมในชุมชนออนไลน์ (Community Engagement) * เป้าหมาย: ได้รับดาว (GitHub Stars)

อย่างน้อย 10 ดวง หรือมีผู้เข้าชมคลังโค้ดมากกว่า 50 ครั้ง ภายในวันที่ 31 พฤษภาคม 2568 * วิธีวัดผล: ตรวจสอบสถิติใน GitHub เช่น ดาว (stars), จำนวน views และ forks

4.3 ตัวชี้วัดด้านการใช้งานจริง (Practical KPIs)

ความสามารถในการแสดงข้อมูลที่มีประโยชน์ (Visualization Utility) * เป้าหมาย: แดชบอร์ดต้องสามารถแสดงข้อมูล 3 ตัวแปร (เช่น PM2.5, อุณหภูมิ, ความชื้น) พร้อมกราฟแบบโต้ตอบได้ (interactive) อย่างน้อย 1 รายการ เช่น กราฟแสดงแนวโน้ม PM2.5 * วิธีวัดผล: ตรวจสอบคุณสมบัติของแดชบอร์ดจริงระหว่างการทดสอบ

ประสิทธิภาพของโมเดลคาดการณ์ (ML Model Performance) * เป้าหมาย: โมเดล Linear Regression ควรมีค่าความแม่นยำ (R^2 score) ไม่น้อยกว่า 0.5 ในการพยากรณ์ค่าฝุ่น PM2.5 * วิธีวัดผล: คำนวณค่า R^2 ด้วย scikit-learn บนข้อมูลที่เก็บได้

ความพึงพอใจของผู้ใช้งาน (Stakeholder Satisfaction) * เป้าหมาย: ได้รับคะแนนความพึงพอใจเฉลี่ยไม่ต่ำกว่า 4 จาก 5 คะแนน จากผู้มีส่วนเกี่ยวข้อง 3-5 คน เช่น อาจารย์หรือผู้สนใจด้านสิ่งแวดล้อม * วิธีวัดผล: แจกแบบสอบถามหรือสัมภาษณ์หลังนำเสนอระบบ

5. ภาพรวมแผนดำเนินโครงการ

ระยะเวลา: 3 สัปดาห์ (ประมาณ 10-15 ชั่วโมงต่อสัปดาห์)

ไทม์ไลน์:

- สัปดาห์ที่ 1 (28 เมษายน – 4 พฤษภาคม): ออกแบบโครงสร้างพื้นฐานและสถาปัตยกรรมข้อมูล, ตั้งค่า GitHub และ Docker ผลลัพธ์ที่คาดหวัง: แผนผังโครงสร้างระบบ, โครงสร้างข้อมูล Parquet, ไฟล์ docker-compose.yml
- สัปดาห์ที่ 2 (5 – 11 พฤษภาคม): พัฒนา Prefect flows, สร้างไฟล์ข้อมูล Parquet และแดชบอร์ดด้วย Streamlit ผลลัพธ์ที่คาดหวัง: ระบบ pipeline ที่ใช้งานได้, แดชบอร์ดพร้อมแสดงผล, คอมมิตบน GitHub
- สัปดาห์ที่ 3 (12 – 18 พฤษภาคม): ติดตั้งระบบ pipeline, ทดสอบการทำงานต่อเนื่อง 24 ชั่วโมงขึ้นไป, ปรับปรุงแดชบอร์ด และจัดทำเอกสารสรุป ผลลัพธ์ที่คาดหวัง: ระบบ pipeline ที่ติดตั้งเสร็จสมบูรณ์, แดชบอร์ดที่ผ่านการทดสอบ, รายงานผลสุดท้าย

ทรัพยากรที่ใช้: * เครื่องมือ: Prefect 3, Docker, Parquet, OpenWeatherMap API (แบบใช้ฟรี), Streamlit, Python * ฮาร์ดแวร์: คอมพิวเตอร์ส่วนตัวหรือเซิร์ฟเวอร์คลาวด์ (RAM 4GB, CPU 2 คอร์, พื้นที่เก็บข้อมูล 20GB) * งบประมาณ: ต่ำมาก (ใช้เครื่องมือฟรีทั้งหมด ยกเว้นหากขยายระบบด้วยบริการคลาวด์)

6. บทสรุป

โครงการ Real-Time PM2.5 Monitoring Dashboard เป็นโอกาสสำคัญในการผสมผสานเป้าหมายทางการศึกษากับการใช้ โดยต่อยอดจากกรอบแนวคิดของโครงการ papapipeline โดยใช้ Docker, Prefect, LakeFS, และ

Streamlit รวมเข้าด้วยกันในการทำ Flow ในการเก็บข้อมูลจนไปถึงการแสดง Data ในรูปแบบ Dashboard บน Streamlit

Start the project

1. Install Docker on your device.

<https://www.docker.com/products/docker-desktop>

2. Clone this Repository:

```
git clone https://github.com/pupa03/dsi321_2025.git
```

Then go into folder dsi321_2025 where docker-compose.yml exist.

```
cd dsi321_2025
```

```
.
├── dsi321_2025
│   └── docker-compose.yml
```

3. Run Docker :

```
docker compose up --build -d
```

[!NOTE] Prefect worker might not get denied permission on wait-for-server.sh
You can give permission by :

```
chmod +x make/wait-for-server.sh
```

4. Create file .env

```
OPENWEATHER_API_KEY=YOUR_API_KEY
```

```
LAKEFS_ACCESS_KEY=access_key
```

```
LAKEFS_SECRET_KEY=secret_key
```

```
LAKEFS_ENDPOINT=http://lakefs-dev:8000/
```

[!NOTE] Your LakeFS_KEY is on docker-compose.yml

5. Create repositories on LakeFS (port:8000)

- 1) weather-data

- 2) pollution-data

6. Deploy flow on jupyter terminal (port:8888)

```
python deploy.py
```

[!WARNING] Don't forget to check that your Prefect-worker still running.

7. Check flow on Prefect-server (port:4200)

On Deployment menu should show main-flow schedule.

wait untill flow finish for first time then check you data on LakeFS.

8. Open Streamlit to see dashboard (port:8501)

แผนที่ค่าฝุ่น PM2.5 รายอำเภอ

เลือกเวลา

2025-05-19 19:45


2025-05-18 20:00

2025-05-19 19:45

ระดับแผนที่

☐ จังหวัด (Province)

☒ อำเภอ (District)



local_timestamp_15min=2025-05-19 18:45:00+07:00

2025-05-19 18:45:00+07:00

2025-05-19 19:15:00+07:00

2025-05-19 19:45:00+07:00

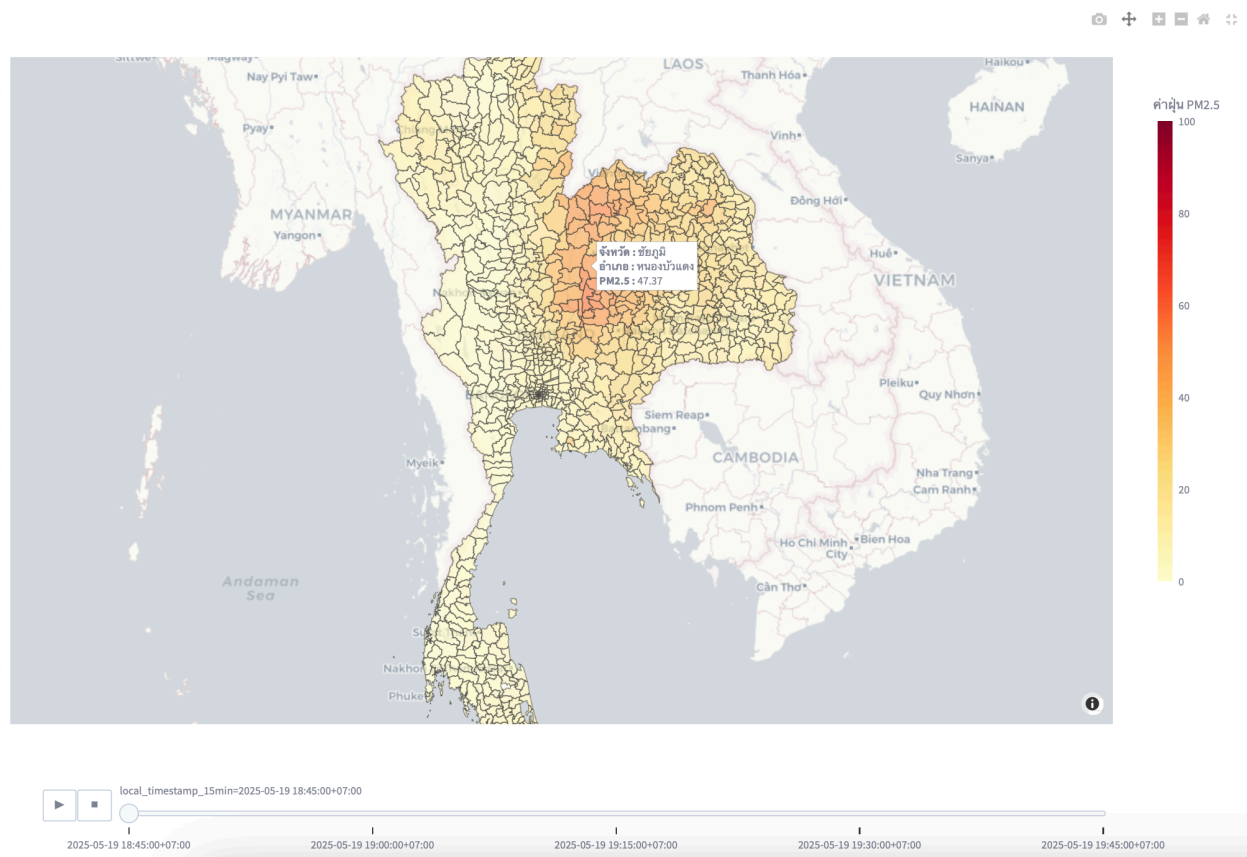


Figure 1: demo2